

Clase 4 – Arquitecturas Avanzadas en Deep Learning para Series de Tiempo

Oscar Rodríguez

Advanced Time Series Analysis

Septiembre 2025

Convenciones y notación

- Longitud total de la secuencia: $T_{\text{total}} = 20$. En esta clase desarrollamos explícitamente los casos $T = 1, 2, 3, 4, 5$.
- Vectores en negrita: $\mathbf{x}_t \in \mathbb{R}^p$, estados $\mathbf{h}_t, \mathbf{c}_t \in \mathbb{R}^n$.
- Productos tipo $\prod_{j=a}^b(\cdot)$: si el índice superior es menor que el inferior, se toma por convención como un vector de unos 1 (*producto vacío*).
- Para índices fuera de rango (por ejemplo x_0, x_{-1}), usamos padding causal con ceros, salvo que se indique un estado inicial $\mathbf{h}_0, \mathbf{c}_0$.

Motivación

- RNN clásicas sufren *desvanecimiento/explosión de gradientes* con secuencias largas; el entrenamiento es estrictamente secuencial.
- Arquitecturas modernas: **LSTM, GRU, TCN, Transformers**.
- Objetivos de la clase:
 - Entender la **matemática** / expansiones cerradas de cada arquitectura.
 - Claridad sobre **complejidad** y **paralelismo**.
 - Buenas prácticas para forecasting univariado y multivariado.

Explicación intuitiva

- **Problema de RNN clásicas:** como una persona que solo recuerda lo último que escuchó, olvidando lo anterior cuando la historia es larga.
- **LSTM:** añade una libreta de memoria con pestañas: puedes borrar (olvido), anotar (entrada) o mostrar (salida).
- **GRU:** es como la LSTM pero más compacta: solo tiene dos botones, uno decide si actualizas o mantienes, otro si usas lo viejo al proponer lo nuevo.
- **TCN:** en lugar de leer palabra por palabra, miras varios pasos atrás a la vez con “ventanas” de distinto tamaño (dilatación), y puedes hacerlo en paralelo.
- **Transformers:** cada paso pregunta directamente al resto “¿a quién debo prestar atención?” y recibe una mezcla de respuestas, sin pasar uno por uno.

Mapa de la clase

- 1 LSTM
- 2 GRU
- 3 TCN
- 4 Transformers
- 5 Práctica
- 6 Cierre

LSTM – Definición y dimensiones

Referencia: Hochreiter & Schmidhuber (1997), *Long Short-Term Memory*.

- Entrada $\mathbf{x}_t \in \mathbb{R}^p$, estado oculto $\mathbf{h}_t \in \mathbb{R}^n$, celda $\mathbf{c}_t \in \mathbb{R}^n$.

- Pesos: $W_* \in \mathbb{R}^{n \times p}$, $U_* \in \mathbb{R}^{n \times n}$, $\mathbf{b}_* \in \mathbb{R}^n$.

$$\mathbf{f}_t = \sigma(W_f \mathbf{x}_t + U_f \mathbf{h}_{t-1} + \mathbf{b}_f),$$

$$\mathbf{i}_t = \sigma(W_i \mathbf{x}_t + U_i \mathbf{h}_{t-1} + \mathbf{b}_i), \quad \tilde{\mathbf{c}}_t = \tanh(W_c \mathbf{x}_t + U_c \mathbf{h}_{t-1} + \mathbf{b}_c),$$

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t,$$

$$\mathbf{o}_t = \sigma(W_o \mathbf{x}_t + U_o \mathbf{h}_{t-1} + \mathbf{b}_o), \quad \mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t).$$

LSTM – Intuición (para dummies)

- Piensa en $\mathbf{c}_t$ como una **libreta** de memoria; $\mathbf{f}_t$ decide qué **olvidar**, $\mathbf{i}_t$ qué **anotar**, y $\mathbf{o}_t$ qué **mostrar** a la salida.
- Las compuertas son números en $(0, 1)$ (sigmoide) que escalan información.
- Si $\mathbf{f}_t \approx 1$ e $\mathbf{i}_t \approx 0$, la memoria persiste; si $\mathbf{f}_t \approx 0$, se borra el pasado.

LSTM – Expansión cerrada en T

Celda:

$$\mathbf{c}_T = \left(\prod_{j=1}^T \mathbf{f}_j \right) \odot \mathbf{c}_0 + \sum_{\tau=1}^T \left(\mathbf{i}_{\tau} \odot \tilde{\mathbf{c}}_{\tau} \odot \prod_{j=\tau+1}^T \mathbf{f}_j \right)$$

Salida: $\mathbf{h}_T = \mathbf{o}_T \odot \tanh(\mathbf{c}_T)$.

- $\prod_{j=\tau+1}^T \mathbf{f}_j$ es un **peso de supervivencia** de la contribución escrita en τ .

LSTM – Ejemplos simbólicos para $T = 1,5$

Convención: $\prod_{j=a}^b f_j = 1$ si $b < a$.

$$\mathbf{c}_1 = \mathbf{f}_1 \odot \mathbf{c}_0 + \mathbf{i}_1 \odot \tilde{\mathbf{c}}_1,$$

$$\mathbf{h}_1 = \mathbf{o}_1 \odot \tanh(\mathbf{c}_1).$$

$$\mathbf{c}_2 = (\mathbf{f}_2 \odot \mathbf{f}_1) \odot \mathbf{c}_0 + \mathbf{f}_2 \odot \mathbf{i}_1 \odot \tilde{\mathbf{c}}_1 + \mathbf{i}_2 \odot \tilde{\mathbf{c}}_2,$$

$$\mathbf{h}_2 = \mathbf{o}_2 \odot \tanh(\mathbf{c}_2).$$

$$\begin{aligned} \mathbf{c}_3 = & (\mathbf{f}_3 \odot \mathbf{f}_2 \odot \mathbf{f}_1) \odot \mathbf{c}_0 + (\mathbf{f}_3 \odot \mathbf{f}_2) \odot \mathbf{i}_1 \odot \tilde{\mathbf{c}}_1 \\ & + \mathbf{f}_3 \odot \mathbf{i}_2 \odot \tilde{\mathbf{c}}_2 + \mathbf{i}_3 \odot \tilde{\mathbf{c}}_3, \end{aligned}$$

$$\mathbf{h}_3 = \mathbf{o}_3 \odot \tanh(\mathbf{c}_3).$$

$$\begin{aligned} \mathbf{c}_4 = & \left(\prod_{j=1}^4 \mathbf{f}_j \right) \odot \mathbf{c}_0 + \left(\prod_{j=2}^4 \mathbf{f}_j \right) \odot \mathbf{i}_1 \odot \tilde{\mathbf{c}}_1 + \left(\prod_{j=3}^4 \mathbf{f}_j \right) \odot \mathbf{i}_2 \odot \tilde{\mathbf{c}}_2 \\ & + \mathbf{f}_4 \odot \mathbf{i}_3 \odot \tilde{\mathbf{c}}_3 + \mathbf{i}_4 \odot \tilde{\mathbf{c}}_4, \end{aligned}$$

$$\mathbf{h}_4 = \mathbf{o}_4 \odot \tanh(\mathbf{c}_4).$$

$$\begin{aligned} \mathbf{c}_5 = & \left(\prod_{j=1}^5 \mathbf{f}_j \right) \odot \mathbf{c}_0 + \left(\prod_{j=2}^5 \mathbf{f}_j \right) \odot \mathbf{i}_1 \odot \tilde{\mathbf{c}}_1 + \left(\prod_{j=3}^5 \mathbf{f}_j \right) \odot \mathbf{i}_2 \odot \tilde{\mathbf{c}}_2 \\ & + (\mathbf{f}_5 \odot \mathbf{f}_4) \odot \mathbf{i}_3 \odot \tilde{\mathbf{c}}_3 + \mathbf{f}_5 \odot \mathbf{i}_4 \odot \tilde{\mathbf{c}}_4 + \mathbf{i}_5 \odot \tilde{\mathbf{c}}_5, \end{aligned}$$

$$\mathbf{h}_5 = \mathbf{o}_5 \odot \tanh(\mathbf{c}_5).$$

Mapa de la clase

1 LSTM

2 GRU

3 TCN

4 Transformers

5 Práctica

6 Cierre

GRU – Definición y dimensiones

Referencia: Cho et al. (2014), *Learning Phrase Representations using RNN Encoder–Decoder for SMT*.

$$\begin{aligned} \mathbf{z}_t &= \sigma(W_z \mathbf{x}_t + U_z \mathbf{h}_{t-1} + \mathbf{b}_z), & \mathbf{r}_t &= \sigma(W_r \mathbf{x}_t + U_r \mathbf{h}_{t-1} + \mathbf{b}_r), \\ \tilde{\mathbf{h}}_t &= \tanh(W_h \mathbf{x}_t + U_h (\mathbf{r}_t \odot \mathbf{h}_{t-1}) + \mathbf{b}_h), \\ \mathbf{h}_t &= (1 - \mathbf{z}_t) \odot \mathbf{h}_{t-1} + \mathbf{z}_t \odot \tilde{\mathbf{h}}_t. \end{aligned}$$

GRU – Intuición (para dummies)

- Es una LSTM compacta: sin celda separada; todo ocurre en $\mathbf{h}_t$.
- $\mathbf{z}_t$ decide **cuánto actualizar**; $\mathbf{r}_t$ decide cuánta info pasada usar al proponer $\tilde{\mathbf{h}}_t$.
- Si $\mathbf{z}_t \approx 0$, persiste el pasado; si $\mathbf{z}_t \approx 1$, domina el candidato.

GRU – Expansión cerrada en T

$$\mathbf{h}_T = \left(\prod_{j=1}^T (1 - \mathbf{z}_j) \right) \odot \mathbf{h}_0 + \sum_{\tau=1}^T \left(\mathbf{z}_{\tau} \odot \tilde{\mathbf{h}}_{\tau} \odot \prod_{j=\tau+1}^T (1 - \mathbf{z}_j) \right)$$

GRU – Ejemplos simbólicos para $T = 1.5$

$$\mathbf{h}_1 = (1 - \mathbf{z}_1) \odot \mathbf{h}_0 + \mathbf{z}_1 \odot \tilde{\mathbf{h}}_1.$$

$$\mathbf{h}_2 = (1 - \mathbf{z}_2)(1 - \mathbf{z}_1) \odot \mathbf{h}_0 + (1 - \mathbf{z}_2) \mathbf{z}_1 \odot \tilde{\mathbf{h}}_1 + \mathbf{z}_2 \odot \tilde{\mathbf{h}}_2.$$

$$\begin{aligned} \mathbf{h}_3 = & (1 - \mathbf{z}_3)(1 - \mathbf{z}_2)(1 - \mathbf{z}_1) \odot \mathbf{h}_0 + (1 - \mathbf{z}_3)(1 - \mathbf{z}_2) \mathbf{z}_1 \odot \tilde{\mathbf{h}}_1 \\ & + (1 - \mathbf{z}_3) \mathbf{z}_2 \odot \tilde{\mathbf{h}}_2 + \mathbf{z}_3 \odot \tilde{\mathbf{h}}_3. \end{aligned}$$

$$\begin{aligned} \mathbf{h}_4 = & \left(\prod_{j=1}^4 (1 - \mathbf{z}_j) \right) \odot \mathbf{h}_0 + \left(\prod_{j=2}^4 (1 - \mathbf{z}_j) \right) \mathbf{z}_1 \odot \tilde{\mathbf{h}}_1 + \left(\prod_{j=3}^4 (1 - \mathbf{z}_j) \right) \mathbf{z}_2 \odot \tilde{\mathbf{h}}_2 \\ & + (1 - \mathbf{z}_4) \mathbf{z}_3 \odot \tilde{\mathbf{h}}_3 + \mathbf{z}_4 \odot \tilde{\mathbf{h}}_4. \end{aligned}$$

$$\begin{aligned} \mathbf{h}_5 = & \left(\prod_{j=1}^5 (1 - \mathbf{z}_j) \right) \odot \mathbf{h}_0 + \left(\prod_{j=2}^5 (1 - \mathbf{z}_j) \right) \mathbf{z}_1 \odot \tilde{\mathbf{h}}_1 + \left(\prod_{j=3}^5 (1 - \mathbf{z}_j) \right) \mathbf{z}_2 \odot \tilde{\mathbf{h}}_2 \\ & + \left(\prod_{j=4}^5 (1 - \mathbf{z}_j) \right) \mathbf{z}_3 \odot \tilde{\mathbf{h}}_3 + (1 - \mathbf{z}_5)^0 \mathbf{z}_5 \odot \tilde{\mathbf{h}}_5. \end{aligned}$$

Mapa de la clase

1 LSTM

2 GRU

3 TCN

4 Transformers

5 Práctica

6 Cierre

TCN – Convoluciones causales y dilatadas

Referencias:

- Lea et al. (2017), *Temporal Convolutional Networks* (CVPR 2017).
- Bai, Kolter & Koltun (2018), *An Empirical Evaluation of Generic Conv. and Recurrent Networks*.

Una capa:
$$y_t = \sum_{k=0}^{K-1} w_k x_{t-dk} \Rightarrow y_t \leftarrow \{x_t, x_{t-d}, \dots, x_{t-(K-1)d}\}.$$

Múltiples capas (campo receptivo):

$$R = 1 + \sum_{\ell=1}^L (K-1) d_{\ell} \quad (\text{p. ej. } d_{\ell} = 2^{\ell-1})$$

Si $d_{\ell} = 2^{\ell-1}$:
$$R = 1 + (K-1)(2^L - 1).$$

TCN – Cómo se componen los filtros

Para dos capas (kernels $w_b^{(1)}$ con dilatación d_1 y $w_a^{(2)}$ con d_2):

$$\alpha_r = \sum_{\substack{a=0..K-1 \\ b=0..K-1 \\ r=a d_2 + b d_1}} w_a^{(2)} w_b^{(1)}, \quad \text{de modo que } y_T = \sum_{r=0}^{R-1} \alpha_r x_{T-r}.$$

Con activaciones no lineales: la dependencia temporal sigue acotada por R , aunque ya no es estrictamente lineal.

TCN – Ejemplos para $T = 1,5$ (capa superior)

Asumiendo padding causal ($x_0 = x_{-1} = \dots = 0$):

$$y_1 = \alpha_0 x_1,$$

$$y_2 = \alpha_0 x_2 + \alpha_1 x_1,$$

$$y_3 = \alpha_0 x_3 + \alpha_1 x_2 + \alpha_2 x_1,$$

$$y_4 = \alpha_0 x_4 + \alpha_1 x_3 + \alpha_2 x_2 + \alpha_3 x_1,$$

$$y_5 = \alpha_0 x_5 + \alpha_1 x_4 + \alpha_2 x_3 + \alpha_3 x_2 + \alpha_4 x_1, \quad (\alpha_r = 0 \text{ si } r \geq R).$$

Mapa de la clase

- 1 LSTM
- 2 GRU
- 3 TCN
- 4 Transformers**
- 5 Práctica
- 6 Cierre

Transformers – Auto-atención escalada

Referencia: Vaswani et al. (2017), *Attention is All You Need*.

- Secuencia $X \in \mathbb{R}^{T \times p}$, proyecciones $W_Q, W_K, W_V \in \mathbb{R}^{p \times d_k}$.
- $Q = XW_Q, K = XW_K, V = XW_V$.

$$\text{Attn}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V$$

Causalidad: máscara triangular estricta para forecasting: en el tiempo t solo se atiende a $1:t$.

Transformers – Máscara causal y posiciones

- **Máscara causal:** anula puntuaciones a posiciones futuras ($j > t$). La fila t de α se normaliza sobre $\{1, \dots, t\}$.
- **Posiciones:** para series temporales, codificar orden/estacionalidad (positional encodings, *time2vec*, calendarios, Fourier).
- **Multi-cabeza:** H cabezas producen vistas complementarias y se concatenan: $\text{Concat}(Z^{(1)}, \dots, Z^{(H)})W_O$.

Transformers – Ejemplos para $T = 1.,5$ (una cabeza)

$$z_1 = v_1, \quad (\alpha_{11} = 1).$$

$$z_2 = \alpha_{21}v_1 + \alpha_{22}v_2, \quad \alpha_{2j} \propto \exp(\langle q_2, k_j \rangle / \sqrt{d_k}), \quad j \leq 2.$$

$$z_3 = \alpha_{31}v_1 + \alpha_{32}v_2 + \alpha_{33}v_3, \quad \text{normalizados sobre } \{1, 2, 3\}.$$

$$z_4 = \sum_{j=1}^4 \alpha_{4j}v_j, \quad z_5 = \sum_{j=1}^5 \alpha_{5j}v_j.$$

Mapa de la clase

- 1 LSTM
- 2 GRU
- 3 TCN
- 4 Transformers
- 5 Práctica**
- 6 Cierre

Complejidad y paralelismo

Modelo	Tiempo por paso	Paralelismo en T
LSTM/GRU	$O(n^2 + np)$	No (secuencial)
TCN	$O(K C^2)$ por capa	Sí (convoluciones 1D)
Transformer	$O(T^2 d_k)$ (atención)	Sí (por capa)

Notas: n tamaño oculto, p entrada, C canales. En Transformers, memoria $O(T^2)$; variantes eficientes reducen a $O(T \log T)/O(T)$ bajo supuestos.

Buenas prácticas para series de tiempo

- **Normalización consciente de tiempo:** escalado por ventana, estandarización por serie/feature.
- **Positional/temporal features:** hora/día/mes, Fourier estacionales, festivos.
- **Regularización:** dropout (en compuertas/atención), weight decay, early stopping.
- **Optimización:** clipping de gradiente (RNN), warmup de LR (Transformers), inicializaciones ortogonales (RNN).
- **Ventanas:** tamaño de ventana $\geq R$ (TCN) o acorde al horizonte de dependencia esperado.

¿Cuándo usar cada una?

- **LSTM/GRU**: datos moderados, dependencias largas pero sin T gigantes; cuando importar interpretabilidad vía compuertas.
- **TCN**: producción con baja latencia, alto paralelismo, control del horizonte temporal via R .
- **Transformer**: múltiples series, contextos muy largos, relaciones globales; considerar variantes eficientes si T grande.

Errores comunes

- TCN: subestimar R (*usar $2L - 1$ en vez de $2^L - 1$ con dilataciones exponenciales*).
- RNN: no aplicar clipping de gradiente; inicializaciones pobres.
- Transformers: olvidar máscara causal en forecasting; no codificar la estacionalidad.

Comparativa e intuiciones

Arquitectura	Ventajas	Limitaciones
LSTM	Ruta de memoria explícita; pesos de supervivencia	Más parámetros; costo secuencial
GRU	Menos parámetros; mezcla exponencial adaptativa	Menos control explícito que LSTM
TCN	Paralelizable; campo receptivo controlable	Dependencia acotada por R si no se aumenta profundidad/dilatación
Transformer	Dependencias globales; paralelizable	$O(T^2)$ memoria/tiempo; requiere datos y tuning

Mapa de la clase

- 1 LSTM
- 2 GRU
- 3 TCN
- 4 Transformers
- 5 Práctica
- 6 Cierre

Bibliografía y recursos

Originales

- LSTM: Hochreiter, S. & Schmidhuber, J. (1997). *Long Short-Term Memory*. [PDF](#).
- GRU: Cho, K. et al. (2014). *Learning Phrase Representations using RNN Encoder–Decoder for SMT*. [arXiv:1409.0473](#).
- TCN (visión): Lea, C. et al. (2017). *Temporal Convolutional Networks*. [CVPR 2017](#).
- TCN (secuencias): Bai, S., Kolter, J.Z., Koltun, V. (2018). *An Empirical Evaluation....* [arXiv:1803.01271](#).
- Transformers: Vaswani, A. et al. (2017). *Attention is All You Need*. [arXiv:1706.03762](#).

Recursos didácticos

- Towards Data Science: [Math behind GRU](#).
- GeeksforGeeks: [Intro LSTM](#).

Puente hacia Clase 5

- Vimos expansiones cerradas (LSTM/GRU), receptivos (TCN) y pesos de atención (Transformers).
- Próximos temas: **incertidumbre, interpretabilidad y control probabilístico** (*Inferencia Bayesiana y Deep Probabilístico*).