

Clase 6 – Causalidad

Oscar Rodríguez

Advanced Time Series Analysis

Octubre 2025

Mapa de la clase

1 Definiciones y antecedentes

2 Causalidad de Granger: Explicación

Definición

La causalidad se define como la *ley en virtud de la cual se producen efectos* y, en estadística, se refiere a *una relación de necesidad de concurrencia de dos variables aleatorias correlacionadas*. Visto de otra forma, dadas las variables X , Y , la causalidad podría verse como un factor condicionante $Y|X$. Dicho de otra forma:

$$P(Y|X) > P(Y|\bar{X}), \quad P(X) > 0. \quad (1)$$

Condiciones de Selltitz et al. (1959)

Hasta 1970, el modelado causal se utilizaba principalmente en las ciencias sociales. Esto se debió al trabajo pionero de **Selltiz et al. (1959)** [1], quienes especificaron tres condiciones para la existencia de causalidad:

- 1 Debe existir una **variación concomitante** entre X y Y .
- 2 Debe haber una **asimetría temporal** u **orden temporal** entre las dos secuencias observadas.
- 3 La covarianza entre X e Y no debe desaparecer cuando se eliminan los efectos de las **variables de confusión**, es decir, aquellas que son causalmente anteriores a ambas.

La primera condición implica correlación entre causa y efecto, aunque una correlación perfecta no implica causalidad. La segunda se basa intuitivamente en la *flecha del tiempo*. La tercera es problemática, ya que requiere descartar todas las causas posibles, lo cual es teóricamente imposible dado el número finito de variables medidas.

Implicaciones del enfoque clásico

Para evitar la indeterminación derivada de variables no observadas, se impone cierta **estructura** al modelo causal. El modo en que dicha estructura se define es crucial para determinar y cuantificar la causalidad. Este enfoque sentó las bases para la transición hacia definiciones **computacionalmente cuantificables** de causalidad, especialmente las desarrolladas por **Wiener (1956)** y **Granger (1969)**.

Definición de Wiener (1956)

La primera definición formal y cuantificable de causalidad fue propuesta por **Norbert Wiener (1956)** [2]:

Idea de Wiener (paráfrasis)

Si la predicción de una señal mejora al usar el pasado de otra, respecto a no usarlo, entonces la segunda es *causal* para la primera.

Esta definición introdujo la idea de causalidad en términos de **mejoría predictiva**, concepto que posteriormente inspiró el enfoque estadístico de Granger.

Causalidad de Granger (1969, 2003)

Clive W. J. Granger [3, 4], inspirado en Wiener, introdujo el concepto de **causalidad de Granger (GC)** en el análisis de series temporales:

- 1 La causa ocurre **antes** que el efecto.
- 2 La causa contiene **información única** sobre el efecto, que no está presente en ninguna otra variable.

De acuerdo con Granger, un proceso X_t **Granger causa** a otro proceso Y_t . Si los valores futuros de Y_t pueden predecirse mejor utilizando los valores pasados de X_t y Y_t que sólo usando los valores pasados de Y_t .

El test estándar de GC se basa en un modelo de **regresión lineal**, donde la mejora en la predicción se evalúa mediante análisis de varianza (ANOVA) o F-test.

Mapa de la clase

1 Definiciones y antecedentes

2 Causalidad de Granger: Explicación

Idea central e intuición

Definición informal (Wiener & Granger)

X *causa* a Y en el sentido de Granger si el **pasado de X** contiene información que **mejora la predicción** del *futuro* de Y por encima de usar solo el pasado de Y .

- Componente temporal: la **causa precede** al efecto.
- Componente informacional: la causa aporta **información única** sobre el efecto (no presente en otras variables incluidas).

Modelo bivariado: forma estándar

Considere dos series estacionarias $\{Y_t\}$ y $\{X_t\}$ y un orden de rezago p :

$$\underbrace{Y_t}_{\text{variable efecto}} = c + \sum_{i=1}^p \alpha_i Y_{t-i} + \sum_{i=1}^p \beta_i X_{t-i} + u_t, \quad u_t \sim \text{i.i.d. } (0, \sigma^2)$$

Hipótesis para “ $X \Rightarrow Y$ ” (Granger)

$$H_0 : \beta_1 = \dots = \beta_p = 0 \quad (\text{no hay GC de } X \text{ a } Y) \quad H_1 : \exists i \text{ tal que } \beta_i \neq 0.$$

- **Modelo no restringido (U)**: incluye rezagos de X y Y .
- **Modelo restringido (R)**: excluye los rezagos de X (solo rezagos de Y).

Prueba F (regresión lineal, muestras moderadas/grandes)

Se estiman por MCO ambos modelos y se obtienen las sumas de residuos al cuadrado: RSS_U (no restringido) y RSS_R (restringido).

$$F = \frac{(RSS_R - RSS_U) / m}{RSS_U / (T - k)},$$

$m=p$ (nº de restricciones), k =parámetros en U , $T=n$ de observaciones.

Regla de decisión (nivel α)

- **Rechazar** H_0 si $F > F_{m, T-k; 1-\alpha}$ o si **p-valor**(F) $< \alpha$.
- En tal caso, concluimos que X **causa a** Y en el sentido de **Granger** (dado p y el resto de la especificación).

Pruebas Wald y de Razón de Verosimilitud (LR)

Wald (forma general): con $\hat{\theta}$ de U y matriz de restricciones R tal que $R\theta = \mathbf{r}$,

$$W = \left(R\hat{\theta} - \mathbf{r}\right)^{\top} \left[R(X^{\top}X)^{-1}R^{\top}\right]^{-1} \left(R\hat{\theta} - \mathbf{r}\right) \xrightarrow{d} \chi_m^2.$$

LR (útil en VAR y MVN):

$$\text{LR} = T \left(\ln |\hat{\Sigma}_R| - \ln |\hat{\Sigma}_U| \right) \xrightarrow{d} \chi_m^2,$$

donde $\hat{\Sigma}_U$ y $\hat{\Sigma}_R$ son estimaciones de la covarianza de errores (U vs. R).

Decisión: Rechazar H_0 si W o $\text{LR} > \chi_{m; 1-\alpha}^2$, o si su p-valor $< \alpha$.

Selección de rezagos y supuestos clave

- Seleccionar p con criterios de información: **AIC**, **BIC**, **HQ**, asegurando **residuos no autocorrelacionados**.
- Se requiere **estacionariedad** de las series.
- Se verifican autocorrelación (Portmanteau/Ljung–Box), normalidad (Jarque–Bera), estabilidad del VAR (raíces dentro del círculo de unidad).

Causalidad instantánea y otras consideraciones

- **Causalidad instantánea:** correlación contemporánea de los errores ($\text{Cov}(u_t, v_t) \neq 0$). No es GC, pero puede testearse vía estructura contemporánea (p.ej., SVAR).
- **Sensibilidad a p y al muestreo:** los resultados pueden cambiar con el orden de rezago o la frecuencia de datos.
- **Variables omitidas:** la GC es *condicional al conjunto de variables*. Incluir Z_t relevante puede cambiar las conclusiones.
- **Robustez:** usar SE robustos; validar con submuestras; considerar **bootstrap** en muestras pequeñas.

Procedimiento paso a paso (bivariado)

- 1 Revisar estacionariedad (ADF/PP); transformar si procede o decidirse por VECM/TY.
- 2 Elegir p (AIC/BIC/HQ) garantizando residuos no autocorrelacionados.
- 3 Estimar:

$$\mathbf{U}: Y_t = c + \sum_{i=1}^p \alpha_i Y_{t-i} + \sum_{i=1}^p \beta_i X_{t-i} + u_t, \quad \mathbf{R}: Y_t = c + \sum_{i=1}^p \alpha_i Y_{t-i} + u_t.$$

- 4 Calcular F :

$$F = \frac{(\text{RSS}_R - \text{RSS}_U)/p}{\text{RSS}_U/(T - k)}.$$

- 5 **Decisión:** rechazar H_0 si $p\text{-valor} < \alpha$; concluir $X \Rightarrow Y$ (GC).
- 6 Repetir para $Y \rightarrow X$ (la direccionalidad puede ser unidireccional o bidireccional).

Referencias I



C. Selltiz, L. S. Wrightsman, S. W. Cook, *Research Methods in Social Relations*, Holt, Rinehart and Winston, New York, 1959.



N. Wiener, *The Theory of Prediction*, en E. F. Beckenbach (ed.), *Modern Mathematics for Engineers*, McGraw-Hill, New York, 1956.



C. W. J. Granger, "Investigating Causal Relations by Econometric Models and Cross-Spectral Methods," *Econometrica*, 37(3), 424–438, 1969.



C. W. J. Granger, "Time Series Analysis, Cointegration, and Applications," *Nobel Lecture*, 2003.



K. Hlaváčková-Schindler, M. Paluš, M. Vejmelka, J. Bhattacharya, "Causality Detection Based on Information-Theoretic Approaches in Time Series Analysis," *Physics Reports*, 441(1), 1–46, 2007.



H. Lütkepohl, *New Introduction to Multiple Time Series Analysis*, Springer, 2005.



H. Y. Toda, T. Yamamoto, "Statistical Inference in Vector Autoregressions with Possibly Integrated Processes," *Journal of Econometrics*, 66(1–2), 225–250, 1995.



S. Johansen, *Likelihood-based Inference in Cointegrated VAR Models*, Oxford University Press, 1995.