

# Clase 7 – Causalidad e Incertidumbre

Oscar Rodríguez

Advanced Time Series Analysis

Octubre 2025

# Definición

La causalidad se define como la *ley en virtud de la cual se producen efectos* y, en estadística, se refiere a *una relación de necesidad de concurrencia entre dos variables aleatorias correlacionadas*. Visto de otra forma, dadas las variables  $X$ ,  $Y$ , la causalidad podría verse como un factor condicionante  $Y|X$ . Dicho de otra forma:

$$P(Y|X) > P(Y|\bar{X}), \quad P(X) > 0. \quad (1)$$

# Mapa de la clase

## 1 Métodos modernos de causalidad en Python

# Entropía de transferencia (TE)

La **entropía de transferencia (transfer entropy, TE)** es una medida de causalidad basada en la teoría de la información propuesta por **Thomas Schreiber (2000)** [1]. Se define como la reducción de la incertidumbre de  $Y$  al conocer el pasado de  $X$ , condicionando por el pasado de  $Y$ . En forma matemática:

Definición (TE como info. mutua condicional)

$$T_{X \rightarrow Y} = H(Y_{t+1} | Y_t) - H(Y_{t+1} | Y_t, X_t),$$

donde  $H(\cdot|\cdot) = -\sum p(\cdot, \cdot) \log p(\cdot|\cdot)$  es entropía condicional [2].

# Entropía de transferencia (TE)

- $T_{X \rightarrow Y} > 0$  indica que  $X$  aporta información adicional para predecir  $Y$  (posible causalidad);  $T_{X \rightarrow Y} = 0$  implica independencia condicional (no causalidad dirigida).
- Para procesos gaussianos lineales, TE y la causalidad de Granger son equivalentes, pero TE captura relaciones *no lineales* y no paramétricas entre series.
- En la práctica se estima a partir de muestras (p. ej., métodos de binning o  $k$ -vecinos más cercanos) y se evalúa su significancia mediante pruebas de permutación.

# Causalidad de Granger no lineal (redes neuronales)

Algunas técnicas recientes extienden la **causalidad de Granger** mediante modelos de **redes neuronales** para captar relaciones no lineales. La idea central es sustituir la regresión lineal por un predictor más flexible:

- **Basado en predicción:** Entrenar dos modelos predictivos para  $Y_t$ . Uno usando únicamente el pasado de  $Y$  (modelo restringido) y otro usando el pasado de  $Y$  y de  $X$  (modelo completo) [3]. Este esquema se implementa con MLP, LSTM, etc. Evaluando la mejora de la precisión fuera de muestra.
- **Estructura de Esparza:** Entrenar redes neuronales multivariadas con regularización para descubrir la estructura causal. Por ejemplo, **Tank et al. (2021)** [4] proponen modelos en los que cada serie es pronosticada por una NN cuyas entradas son los rezagos de todas las series, aplicando un *penalizador de grupo Lasso* en los pesos de entrada. Este penalizador anula grupos de pesos, identificando automáticamente las entradas que no contribuyen (causalmente) al pronóstico de  $Y$ .

Estos métodos detectan causalidad no lineal más allá del marco lineal de Granger. Sin embargo, requieren **mayores cantidades de datos**.

# Referencias I

- [1] T. Schreiber, "Measuring Information Transfer," *Phys. Rev. Lett.*, 85(2), 461–464, 2000.
- [2] K. Hlaváčková-Schindler, M. Paluš, M. Vejmelka, J. Bhattacharya, "Causality Detection Based on Information-Theoretic Approaches in Time Series Analysis," *Physics Reports*, 441(1), 1–46, 2007.
- [3] M. Rosoń, M. Młyńczak, G. Cybulski, "Granger causality test with nonlinear neural-network-based methods: Python package and simulation study," *Comput. Methods Programs Biomed.*, 216:106669, 2022.
- [4] A. Tank, I. Covert, N. Foti, A. Shojaie, E. B. Fox, "Neural Granger Causality," *IEEE T. Pattern Anal. Mach. Intell.*, 43(5), 1470–1482, 2021.
- [5] J. Runge, et al., "Causal network reconstruction from time series in Earth sciences," *PNAS*, 115(31), E7219–E7228, 2018.
- [6] J. Runge, "Discovering causal relationships in multivariate time series datasets," *J. Open Source Software*, 5(54): 2470, 2020.