

Clase 8 – Incertidumbre en Series de Tiempo

Oscar Rodríguez

Advanced Time Series Analysis

Noviembre 2025

Planteamiento

En el análisis de series de tiempo, el objetivo no sólo es predecir el valor futuro de una variable, sino también **cuantificar la incertidumbre** asociada a esa predicción.

Toda estimación está sujeta a múltiples fuentes de incertidumbre, incluidas:

- **Ruido aleatorio:** variabilidad inherente al sistema.
- **Error de modelo:** simplificaciones o supuestos incorrectos.
- **Cambio estructural:** alteraciones en la dinámica temporal.

El desafío consiste en construir modelos que no sólo pronostiquen bien, sino que también expresen **qué tan confiables son sus predicciones**.

Mapa de la clase

- 1 **Introducción a la incertidumbre**
- 2 Enfoques probabilísticos y bayesianos
- 3 Método Monte Carlo Dropout
- 4 Ejemplos de incertidumbre en RNN, LSTM y GRU
- 5 Conclusiones

Motivación

La mayoría de los modelos deterministas, como ARIMA o LSTM estándar, producen un único valor de salida, $\hat{y}_{t+h}$, para un horizonte h . Sin embargo, este enfoque ignora la **distribución de probabilidad** de los posibles resultados.

Idea central

En lugar de predecir un solo valor, queremos estimar una **distribución predictiva**:

$$p(y_{t+h} \mid y_{1:t})$$

donde cada resultado posible tiene una probabilidad asociada.

Esto permite construir **intervalos de confianza, bandas de predicción y medidas de riesgo**, fundamentales en contextos reales (finanzas, energía, salud, clima, etc.).

Fuentes de incertidumbre

Existen tres fuentes principales de incertidumbre en series de tiempo:

1. Incertidumbre aleatoria (inherente o irreducible)

Proviene de la variabilidad natural del proceso estocástico. Incluso con un modelo perfecto, los valores futuros contienen ruido:

$$Y_t = f(X_t) + \varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, \sigma^2)$$

2. Incertidumbre epistémica (modelo o datos)

Se debe a un conocimiento insuficiente del modelo o a la escasez de datos. Puede reducirse mediante más observaciones o mediante modelos más expresivos.

3. Incertidumbre estructural

Aparece cuando el modelo no representa correctamente la dinámica real, como en presencia de cambios de régimen o de shocks externos.

Mapa de la clase

- 1 Introducción a la incertidumbre
- 2 Enfoques probabilísticos y bayesianos
- 3 Método Monte Carlo Dropout
- 4 Ejemplos de incertidumbre en RNN, LSTM y GRU
- 5 Conclusiones

Modelado probabilístico de predicciones

Una forma natural de representar la incertidumbre es modelar explícitamente la **distribución de salida**:

$$Y_t \sim \mathcal{N}(\mu_\theta(x_t), \sigma_\theta^2(x_t))$$

donde:

- $\mu_\theta(x_t)$ representa el valor esperado (predicción media),
- $\sigma_\theta^2(x_t)$ cuantifica la varianza condicional (incertidumbre).

En redes neuronales, ambos términos pueden ser aprendidos simultáneamente mediante la maximización de la *log-verosimilitud*:

$$\log p(Y_t | X_t) = -\frac{1}{2} \left[\log \sigma_\theta^2 + \frac{(Y_t - \mu_\theta)^2}{\sigma_\theta^2} \right] + C$$

Incertidumbre en redes neuronales

Los modelos de **Deep Learning probabilístico** permiten estimar incertidumbre sin modificar drásticamente la arquitectura:

- **Dropout bayesiano** (*Gal & Ghahramani, 2016*): mantener el dropout activado durante la inferencia y muestrear múltiples predicciones.
- **Ensembles de modelos** (*Lakshminarayanan et al., 2017*): entrenar varias redes independientes y combinar sus salidas.
- **Redes bayesianas** (BNNs): asignar distribuciones sobre los pesos $p(\theta)$ y estimar la posterior $p(\theta|D)$.
- **Modelos generativos** (VAE, MDN): aprender distribuciones multimodales sobre las predicciones.

Cada técnica ofrece una forma distinta de representar las posibles trayectorias futuras del sistema.

Ejemplo conceptual

- **Predicción determinista:**

$$\hat{y}_{t+1} = f_{\theta}(y_t)$$

Un único valor, sin información sobre la confiabilidad.

- **Predicción probabilística:**

$$p(y_{t+1}|y_t) = \mathcal{N}(\mu_{\theta}(y_t), \sigma_{\theta}^2(y_t))$$

Devuelve tanto el valor medio como el intervalo de confianza.

Ejemplo de salida:

Predicción esperada: 105,2, 95 % PI: [101,3, 108,9]

Interpretar la predicción como una distribución mejora la toma de decisiones basada en el riesgo.

Mapa de la clase

- 1 Introducción a la incertidumbre
- 2 Enfoques probabilísticos y bayesianos
- 3 Método Monte Carlo Dropout**
- 4 Ejemplos de incertidumbre en RNN, LSTM y GRU
- 5 Conclusiones

Fundamento del MC Dropout

El método **Monte Carlo Dropout (MC Dropout)** [1] ofrece una forma práctica de estimar la **incertidumbre epistémica** en redes neuronales.

Idea central

Mantener el *dropout* activado durante la inferencia y ejecutar múltiples predicciones:

$$\hat{y}^{(i)} = f_{\theta, m^{(i)}}(x)$$

donde $m^{(i)}$ es una máscara aleatoria de neuronas activas. Cada ejecución produce una muestra de la distribución predictiva.

- Fácil de implementar.
- No requiere cambios en la arquitectura.
- Compatible con RNN, LSTM, GRU y Transformers.

Interpretación bayesiana

El dropout puede interpretarse como una **aproximación de Monte Carlo** a la inferencia bayesiana sobre los pesos:

$$p(y|x, D) = \int p(y|x, \theta) p(\theta|D) d\theta$$

MC Dropout aproxima esta integral mediante N muestras:

$$p(y|x, D) \approx \frac{1}{N} \sum_{i=1}^N \delta(y - f_{\theta, m^{(i)}}(x))$$

- Cada máscara $m^{(i)}$ define un conjunto distinto de pesos activos.
- La dispersión de las salidas refleja la confianza del modelo.

Estimación de la incertidumbre

Media y varianza de las predicciones

$$\mathbb{E}[Y] \approx \frac{1}{N} \sum_{i=1}^N \hat{y}^{(i)}, \quad \text{Var}(Y) \approx \frac{1}{N} \sum_{i=1}^N (\hat{y}^{(i)} - \mathbb{E}[Y])^2$$

La desviación estándar σ_t cuantifica la **incertidumbre epistémica** del modelo.

Intervalo de confianza (95 %)

$$I_{95}(t) = [\mathbb{E}[Y_t] - 1,96 \sigma_t, \mathbb{E}[Y_t] + 1,96 \sigma_t]$$

Un intervalo más ancho $\Rightarrow$ menor confianza.

Explicación del método

- Cada pasada del modelo con *dropout* activado corresponde a una versión distinta de los pesos.
- Si las predicciones son consistentes $\Rightarrow$ baja incertidumbre.
- Si varían mucho $\Rightarrow$ alta incertidumbre.

Mapa de la clase

- 1 Introducción a la incertidumbre
- 2 Enfoques probabilísticos y bayesianos
- 3 Método Monte Carlo Dropout
- 4 Ejemplos de incertidumbre en RNN, LSTM y GRU
- 5 Conclusiones

Incertidumbre en redes recurrentes (RNN)

Las **Redes Neuronales Recurrentes (RNN)** modelan secuencias temporales mediante:

$$h_t = f(Wx_t + Uh_{t-1} + b), \quad \hat{y}_t = g(Vh_t)$$

El estado oculto h_t resume el pasado, pero:

- Si el modelo está mal entrenado o los datos son ruidosos, h_t resulta incierto.
- La **propagación del error** incrementa la incertidumbre a medida que aumenta el horizonte.

Ejemplo teórico: RNN y acumulación de incertidumbre

Si el error en cada paso tiene varianza σ_ε^2 , el error total a h pasos es:

$$\text{Var}(\hat{y}_{t+h}) = \sigma_\varepsilon^2 \sum_{i=0}^{h-1} \phi^{2i},$$

donde ϕ es la sensibilidad a los rezagos ($|\phi| < 1$).

Interpretación:

- La incertidumbre aumenta a medida que aumenta el horizonte de predicción.
- Análogo a la explosión del gradiente durante el entrenamiento.

Incertidumbre en LSTM: memoria y olvido

$$\begin{aligned}f_t &= \sigma(W_f x_t + U_f h_{t-1} + b_f), & i_t &= \sigma(W_i x_t + U_i h_{t-1} + b_i), \\c_t &= f_t \odot c_{t-1} + i_t \odot \tilde{c}_t, & h_t &= o_t \odot \tanh(c_t)\end{aligned}$$

Interpretación

La puerta de olvido f_t filtra la incertidumbre del pasado. Si $f_t \approx 1$, memoria larga (baja incertidumbre). Si $f_t \approx 0$, reinicio (alta incertidumbre).

Incertidumbre en GRU: mezcla de memorias

$$z_t = \sigma(W_z x_t + U_z h_{t-1}), \quad r_t = \sigma(W_r x_t + U_r h_{t-1}),$$
$$h_t = (1 - z_t) \odot h_{t-1} + z_t \odot \tilde{h}_t$$

Varianza del estado

$$\text{Var}(h_t) = (1 - z_t)^2 \text{Var}(h_{t-1}) + z_t^2 \text{Var}(\tilde{h}_t)$$

El coeficiente z_t determina cuánto del pasado se conserva. Cuando z_t fluctúa, el modelo refleja incertidumbre sobre la información retenida.

Comparación conceptual: RNN vs LSTM vs GRU

Modelo	Control del flujo	Propagación de incertidumbre	Capacidad de memoria
RNN	Recurrencia simple	Acumulación exponencial de error	Limitada
LSTM	Puertas de olvido, entrada y salida	Filtrado selectivo de incertidumbre	Alta (memoria larga)
GRU	Puertas de actualización y reinicio	Mezcla estocástica de memorias	Moderada (eficiente)

Conclusión: LSTM y GRU funcionan como filtros probabilísticos que estabilizan la propagación de la incertidumbre en el tiempo.

Mapa de la clase

- 1 Introducción a la incertidumbre
- 2 Enfoques probabilísticos y bayesianos
- 3 Método Monte Carlo Dropout
- 4 Ejemplos de incertidumbre en RNN, LSTM y GRU
- 5 Conclusiones

Resumen de la clase

- 1 La incertidumbre es inherente a toda predicción temporal.
- 2 Distinguimos tres tipos: aleatorios, epistémicos y estructurales.
- 3 Los modelos probabilísticos y bayesianos permiten representarla explícitamente.
- 4 MC Dropout ofrece una herramienta práctica para estimar la incertidumbre en el deep learning.
- 5 LSTM y GRU actúan como filtros que modulan la incertidumbre a lo largo del tiempo.

Referencias I

- [1] Y. Gal, Z. Ghahramani, "Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning," *ICML*, 2016.
- [2] B. Lakshminarayanan, A. Pritzel, C. Blundell, "Simple and Scalable Predictive Uncertainty Estimation using Deep Ensembles," *NeurIPS*, 2017.
- [3] S. Fort, H. Hu, B. Lakshminarayanan, "Deep Ensembles: A Loss Landscape Perspective," *arXiv:1912.02757*, 2019.
- [4] T. Pearce et al., "Uncertainty in Neural Networks: Bayesian Ensembling," *JMLR*, 2020.
- [5] T. Gneiting, A. Raftery, "Strictly Proper Scoring Rules, Prediction, and Estimation," *JASA*, 102(477), 359–378, 2007.